

KẾT HỢP MÔ HÌNH NGÔN NGỮ LỚN VÀ TỔNG HỢP TIẾNG NÓI ĐỂ CẢI THIẾN NGỮ ĐIỆU TRONG ĐỌC VĂN BẢN TỰ ĐỘNG

Combining LLM and TTS to Improve Prosody in Automatic Text-to-Speech

Thành viên thực hiện:

Nguyễn Thị Bảo Trân (52200089@student.tdtu.edu.vn)

Nguyễn Minh Thuận (52200078@student.tdtu.edu.vn)

Giảng viên hướng dẫn:

TS. Trần Thanh Phước (tranthanhphuoc@tdtu.edu.vn)

Trường Đại học Tôn Đức Thắng, Quận 7, TP.HCM

Tóm tắt nội dung

Bài báo đề xuất một khung hệ thống tổng hợp tiếng nói (TTS) tự động, tích hợp mô hình ngôn ngữ lớn (LLM) với các công nghệ TTS hiện đại nhằm nâng cao ngữ điệu và tính biểu cảm của giọng đọc. Trọng tâm của phương pháp này là khai thác khả năng phân tích ngữ nghĩa sâu của LLM để suy diễn các yếu tố biểu cảm quan trọng như điểm nhấn ngữ nghĩa, ngắt quãng phù hợp và trọng âm ở cấp câu/đoạn; truyền tải các tín hiệu prosody được suy diễn này vào bộ TTS tiên tiến để điều khiển chính xác cao độ, trường độ và cường độ của âm thanh đầu ra. Chúng tôi tổng quan cơ sở lý thuyết liên quan bao gồm kiến trúc Matcha-TTS và Conditional Flow Matching (CFM), Large Language Models (LLMs), qua đó đề xuất định hướng cải tiến cụ thể cho ngôn ngữ giàu thanh điệu như tiếng Việt. Mục tiêu cuối cùng là đạt được chất lượng giọng đọc tiệm cận giọng người tự nhiên và biểu cảm.

Từ khóa: Chuyển văn bản thành giọng nói, Mô hình ngôn ngữ lớn, Matcha-TTS, Giọng đọc biểu cảm.

1 Giới thiệu

1.1 Bối cảnh thực hiện

Chất lượng của các hệ thống tổng hợp tiếng nói tự động phụ thuộc không chỉ vào độ chính xác từ vựng mà còn ở khả năng nắm bắt ngữ cảnh (context), thực thể (entities) và quan hệ ngữ nghĩa (semantic relations) giữa chúng. Các hệ thống TTS truyền thống, đặc biệt là các mô hình đơn giản hóa sự phức tạp của ngữ điệu, thường tạo ra giọng đọc đơn điệu, thiếu ngắt nghỉ và nhấn nhá tự nhiên. Điều này làm giảm đáng kể khả năng hiểu và trải nghiệm của người nghe.

Sự phát triển của mô hình ngôn ngữ lớn (LLM) đã mở ra khả năng phân tích ngữ nghĩa sâu và trích xuất cấu trúc văn bản. Khả năng này có thể được khai thác để cung cấp tín hiệu điều kiện ngữ điệu (prosody conditioning signals) giàu bối cảnh cho các bộ TTS, cải thiện đáng kể tính tự nhiên và khả năng biểu cảm của giọng đọc. Sự kết hợp LLM-TTS là giải pháp đầy hứa hẹn để đạt được giọng đọc biểu cảm cao cấp, đặc biệt hữu ích trong các ứng dụng dịch thuật, giáo dục, trợ lý ảo và hỗ trợ tiếp cận thông tin.

1.2 Mục tiêu đề án

Mục tiêu cốt lõi của nghiên cứu này là xây dựng một kiến trúc pipeline đọc văn bản tự động theo hướng tích hợp giữa mô hình ngôn ngữ lớn (LLM) và mô hình tổng hợp tiếng nói (TTS). Trước hết, LLM được khai thác để phân tích ngữ nghĩa và suy diễn cấu trúc ngữ điệu của văn bản, bao gồm các vị trí nhấn trọng tâm thông tin, điểm ngắt câu/ngắt đoạn và các tín

hiệu nhân nhá cần thiết; các thông tin này sau đó được mã hóa dưới dạng nhân prosody có thể điều khiển (ví dụ theo phong cách SSML). Trên cơ sở các tín hiệu điều kiện từ LLM, mô hình TTS thực hiện tổng hợp tiếng nói với cơ chế điều khiển tường minh các tham số âm học quan trọng như cao độ, trường độ và cường độ, nhằm tạo ra giọng đọc có tính tự nhiên và mức độ biểu cảm tiệm cận giọng người. Hiệu quả của hệ thống được đánh giá toàn diện thông qua các thước đo chất lượng giọng đọc, bao gồm Mean Opinion Score (MOS) và các tiêu chí liên quan đến tính tự nhiên (naturalness) cũng như mức độ biểu cảm (expressiveness).

1.3 Phạm vi nghiên cứu

Nghiên cứu tập trung vào các loại văn bản phổ thông, thông tin. LLM chịu trách nhiệm cho cả quá trình phân tích ngữ nghĩa để xuất ra tín hiệu điều kiện (prosody tags, trọng âm thực thể). Bộ TTS tiếp nhận tín hiệu này để tổng hợp giọng nói tiếng Việt. Đầu ra là tệp âm thanh. Thí nghiệm sẽ đặc biệt nhấn mạnh các thách thức và đặc thù của việc mô hình hóa thanh điệu tiếng Việt trong bối cảnh điều khiển ngữ điệu.

2 Kiến thức nền tảng

2.1 Công trình liên quan

2.1.1 Công trình nghiên cứu nổi bật

Lĩnh vực Text-to-Speech (TTS) đã trải qua những bước tiến vượt bậc kể từ năm 2016 nhờ các mô hình học sâu. Quá trình tiến hóa này bao gồm các giai đoạn: mô hình tự hồi quy (autoregressive), phi tự hồi quy (non-autoregressive), mô hình dựa trên Diffusion và gần đây là các mô hình Codec-based (mô hình ngôn ngữ trên mã âm thanh rời rạc). Các công trình dưới đây trình bày các mốc phát triển chính, tạo nền tảng cho thế hệ TTS hiện đại với khả năng zero-shot, đa ngôn ngữ và điều khiển phong cách giọng nói.

- van den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., & Kavukcuoglu, D. (2016). *WaveNet: A Generative Model for Raw Audio*. Giới thiệu WaveNet, một mô hình tự hồi quy tiên phong cho tổng hợp tiếng nói bằng cách dự đoán trực tiếp dạng sóng (waveform) từng mẫu âm thanh. WaveNet mô phỏng phân phối xác suất có điều kiện của mẫu kế tiếp dựa trên chuỗi các mẫu trước, sử dụng mạng tích chập nhân quả (causal convolution). Mô hình này thể hiện khả năng tái tạo chi tiết cao của giọng người, bao gồm cả tiếng thở và độ rung tự nhiên, vượt trội so với các vocoder truyền thống như Griffin-Lim hay WORLD. Ngoài ra, WaveNet có thể điều kiện hóa theo người nói hoặc văn bản, giúp nó trở thành nền tảng của các hệ thống TTS neural sau này.[1]
- Shen, J., Pang, R., Weiss, R. J., Battenberg, E., Chen, Y., Novik, G., Sercu, T., & Coates, A. (2017/2018). *Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions*. Phát triển Tacotron 2, một hệ thống end-to-end TTS kết hợp mạng seq2seq với attention để dự đoán mel-spectrogram từ văn bản, sau đó dùng vocoder WaveNet để chuyển đổi thành sóng âm. Tacotron 2 loại bỏ hoàn toàn giai đoạn trung gian phức tạp (như trích xuất đặc trưng ngôn ngữ), huấn luyện toàn bộ pipeline trong cùng một mạng nơ-ron. Kết quả đạt MOS 4.53, gần tương đương giọng thu âm thật. Mô hình này trở thành chuẩn mực cho các nghiên cứu TTS sau đó, định hình hướng tiếp cận “chữ → mel → waveform”. [2]
- Prenger, R., Valle, R., & Catanzaro, B. (2018). *WaveGlow: A Flow-based Generative Network for Speech Synthesis*. Giới thiệu WaveGlow, một mô hình vocoder dựa trên normalizing flow, kế thừa ý tưởng từ Glow và WaveNet nhưng phi tự hồi quy. WaveGlow cho phép tổng hợp sóng âm liên tục và nhanh hơn hàng chục lần so với WaveNet mà vẫn đạt chất lượng tương đương. Mô hình được huấn luyện bằng kết hợp giữa likelihood loss và STFT loss, không

cần teacher-student distillation. WaveGlow đánh dấu bước tiến trong việc đơn giản hóa huấn luyện vocoder và là lựa chọn phổ biến cho nhiều pipeline TTS đến năm 2020.[3]

- Yamamoto, R., Song, E., & Kim, J.-M. (2019/2020). *Parallel WaveGAN: A Fast, High-Fidelity Neural Vocoder*. Đề xuất Parallel WaveGAN, một GAN-based vocoder sử dụng generator tạo sóng từ mel-spectrogram và discriminator đa độ phân giải để đánh giá đặc trưng phổ âm thanh. Bằng việc tối ưu multi-resolution STFT loss cùng adversarial loss, mô hình này học được sự mượt mà và chi tiết của sóng âm mà không cần huấn luyện distillation như Parallel WaveNet. Parallel WaveGAN đạt tốc độ real-time và kích thước nhẹ, được ứng dụng rộng rãi trong sản phẩm thương mại và nghiên cứu.[4]
- Ren, Y., Ruan, Y., Tan, X., Qin, S., Zhao, Z., & Liu, T.-Y. (2019). *FastSpeech: Fast, Robust and Controllable Text to Speech*. Giới thiệu FastSpeech, một feed-forward Transformer được thiết kế nhằm khắc phục hạn chế chậm và không ổn định của Tacotron. Thay vì dự đoán tuần tự, FastSpeech sử dụng length regulator để căn chỉnh độ dài mel-spectrogram theo văn bản, cho phép sinh song song toàn bộ chuỗi. Mô hình đạt tốc độ sinh nhanh gấp 270 lần so với Tacotron và giảm lỗi lặp/thiếu từ. FastSpeech đánh dấu bước ngoặt trong việc phi tự hồi quy hóa mô hình TTS.[5]
- Ren, Y., Ruan, Y., Tan, X., Qin, S., Zhao, Z., & Liu, T.-Y. (2020). *FastSpeech 2: Fast and High-Quality Speech Synthesis via Non-Autoregressive Models*. Tiếp tục mở rộng FastSpeech bằng cách loại bỏ hoàn toàn pipeline teacher-student vốn phụ thuộc vào aligner ngoài, đồng thời đưa trực tiếp các yếu tố ngữ điệu quan trọng như pitch, energy và duration vào huấn luyện theo hướng dự đoán tường minh. Điểm nổi bật của FastSpeech 2 nằm ở việc tách riêng các nguồn biến thiên của lời nói (nhịp điệu, cường độ, cao độ) và học chúng như các đặc trưng có thể điều khiển, giúp mô hình không chỉ nhanh và ổn định hơn so với Tacotron-style attention mà còn cải thiện đáng kể tính tự nhiên về nhấn giọng và tốc độ đọc. Công trình này đã trở thành một baseline mạnh cho hướng TTS phi tự hồi quy có điều khiển prosody, đồng thời đặt nền móng cho các nghiên cứu sau về controllable TTS và expressive TTS.[6]
- Kong, J., Kim, J., & Bae, J. (2020). *HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis*. HiFi-GAN đánh dấu bước nhảy quan trọng của vocoder GAN khi thiết kế hệ thống discriminator đa chu kỳ và đa tỷ lệ (multi-period & multi-scale) nhằm mô hình hóa đồng thời cấu trúc tuần hoàn của giọng nói và hình dạng phổ âm ở nhiều độ phân giải. Điểm nổi bật của bài báo là đạt chất lượng cảm nhận rất cao (MOS xấp xỉ mức tiệm cận SOTA ở thời điểm công bố) trong khi tốc độ suy luận vượt trội, giúp HiFi-GAN nhanh chóng trở thành lựa chọn mặc định trong nhiều pipeline TTS hiện đại. Ngoài việc cải thiện chất lượng, đóng góp quan trọng của HiFi-GAN còn nằm ở tính “thực dụng” cho triển khai: mô hình gọn, ổn định trong huấn luyện và dễ tích hợp với nhiều acoustic model khác nhau.[7]
- Kong, J., Kim, J., Bae, J., & Seo, J. (2020). *DiffWave: A Versatile Diffusion Model for Audio Synthesis*. DiffWave là một trong các công trình đầu tiên chứng minh diffusion có thể thay thế GAN trong vocoding với ưu thế huấn luyện ổn định và chất lượng tái tạo mượt. Điểm nổi bật của DiffWave nằm ở cơ chế học quá trình khử nhiễu nhiều bước để phục hồi waveform từ điều kiện mel-spectrogram, cho phép điều chỉnh trade-off giữa chất lượng và tốc độ bằng cách thay đổi số bước suy luận. Công trình này có ý nghĩa nền tảng vì mở rộng diffusion từ ảnh sang âm thanh và kích hoạt một nhánh nghiên cứu mạnh về diffusion/score-based speech generation trong các năm tiếp theo.[8]
- Chen, N., Zhang, Y., Zen, H., Weng, C., Yu, Z., & Wang, C. (2020/2021). *WaveGrad: Estimating Gradients for Waveform Generation*. WaveGrad tiếp tục củng cố hướng diffusion/score-based cho âm thanh bằng cách học gradient (score) của phân phối waveform có điều kiện

theo mel. Điểm nổi bật là cách thiết kế tiến trình khử nhiễu và objective giúp mô hình hội tụ hiệu quả và tạo waveform giàu chi tiết, đồng thời vẫn cho phép kiểm soát tốc độ thông qua số bước sampling. Bài báo này quan trọng ở chỗ nó nhấn mạnh “động lực học suy luận” của diffusion: chất lượng tăng dần theo bước, tạo ra một cơ chế điều chỉnh mềm thay vì một cấu hình cố định như GAN vocoder.[9]

- Kim, J., Kim, S., Kong, J., & Yoon, S. (2020). *Glow-TTS: A Generative Flow for Text-to-Speech via Monotonic Alignment Search*. Glow-TTS là cột mốc then chốt cho TTS phi tự hồi quy nhờ kết hợp normalizing flow với Monotonic Alignment Search (MAS) để học căn chỉnh đơn điệu giữa văn bản và mel mà không cần attention. Điểm nổi bật của Glow-TTS là giải quyết đồng thời hai vấn đề của attention-based TTS: (i) lỗi lặp/thiếu từ do attention không ổn định và (ii) suy luận chậm do sinh tuần tự. Bằng MAS, mô hình đạt huấn luyện ổn định hơn và cho phép tổng hợp song song ở mức mel, trở thành nền tảng trực tiếp cho các mô hình kế thừa như Grad-TTS và các biến thể flow/diffusion TTS về sau.[10]
- Kim, J., Kim, S., Kong, J., & Yoon, S. (2021). *VITS: Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech*. VITS nổi bật nhờ hợp nhất acoustic model và vocoder trong cùng một kiến trúc end-to-end, kết hợp variational inference, normalizing flow và adversarial training để sinh trực tiếp waveform chất lượng cao. Điểm mạnh cốt lõi là stochastic duration predictor giúp mô hình hóa nhịp điệu tự nhiên hơn so với duration predictor tất định, đồng thời giảm phụ thuộc vào các module rời rạc. VITS trở thành baseline cực mạnh vì cân bằng tốt giữa chất lượng, tính biểu cảm và khả năng mở rộng (đa người nói/đa ngôn ngữ), và cũng là “điểm xuất phát” cho nhiều hệ expressive TTS sau này.[11]
- Popov, V., Vovk, I., Gogoryan, V. và cộng sự (2021). *Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech*. Grad-TTS chuyển trọng tâm từ flow sang diffusion cho bài toán sinh mel-spectrogram, kết hợp MAS để đảm bảo căn chỉnh đơn điệu và dùng diffusion decoder để tăng chất lượng tái tạo. Điểm nổi bật là khả năng kiểm soát chất lượng–tốc độ bằng số bước diffusion, đồng thời cho thấy diffusion có thể cạnh tranh mạnh với VITS về chất lượng cảm nhận. Grad-TTS có vai trò như “cầu nối” quan trọng dẫn tới các mô hình flow-matching/ODE sau này (bao gồm cả Matcha-TTS) nhằm giảm số bước suy luận mà vẫn duy trì chất lượng.[12]
- Casanova, E., Weber, J., Shulby, C. D. và cộng sự (2022). *YourTTS: Zero-Shot Multi-Speaker Text-to-Speech with Quality and Control*. YourTTS mở rộng VITS theo hướng đa ngôn ngữ và đa người nói với khả năng zero-shot speaker adaptation, tức có thể thích nghi giọng mới từ rất ít dữ liệu tham chiếu. Điểm nổi bật là việc chứng minh khung end-to-end vẫn có thể đạt speaker similarity cao trong thiết lập cross-lingual, đồng thời duy trì chất lượng tự nhiên. Công trình này quan trọng vì đặt nền tảng thực nghiệm cho xu hướng “TTS như một mô hình sinh có điều kiện theo tham chiếu” thay vì chỉ là mapping text-to-speech cố định.[13]
- Lee, S.-g., Ping, W., Ginsburg, B. và cộng sự (2022). *BigVGAN: A Universal Neural Vocoder with Large-Scale Training*. BigVGAN nhấn mạnh lợi ích của huấn luyện quy mô lớn cho vocoder (scaling) và tối ưu hóa kiến trúc để tổng quát tốt trên nhiều miền dữ liệu. Điểm nổi bật là khả năng sinh waveform giàu chi tiết và ổn định trong nhiều điều kiện âm thanh khác nhau, giúp giảm “domain mismatch” khi áp dụng sang giọng, ngôn ngữ hoặc chất lượng ghi âm mới. Đây là một bước quan trọng trong xu hướng phổ quát hóa vocoder, hỗ trợ trực tiếp cho các pipeline TTS/VC hiện đại.[14]
- Shen, K., Ju, Z., Tan, X. và cộng sự (2023). *NaturalSpeech 2: Latent Diffusion Models are Effective for Zero-Shot Text-to-Speech*. NaturalSpeech 2 nổi bật ở việc dịch chuyển diffusion sang không gian latent của neural audio codec thay vì mel-spectrogram, từ đó tăng hiệu quả

mô hình hóa và cải thiện khả năng zero-shot. Điểm quan trọng của bài báo là xem codec representation như “đơn vị sinh” phù hợp hơn cho lời nói, giúp duy trì speaker characteristics tốt và mở rộng sang thiết lập few-shot/zero-shot mạnh mẽ hơn. Công trình này thúc đẩy mạnh xu hướng codec-based TTS và kết nối trực tiếp với các hướng Speech-LM.[15]

- Le, H. B. và cộng sự (2023). *Voicebox: Text-Guided Speech Infilling and Editing*. Voicebox là công trình tiêu biểu đưa flow matching vào âm thanh theo hướng đa nhiệm (inpainting, editing, TTS), nhấn mạnh khả năng “biên tập” lời nói dựa trên văn bản và ngữ cảnh. Điểm nổi bật là framing speech generation như một bài toán khôi phục có điều kiện, tăng tính linh hoạt cho ứng dụng thực tế (sửa từ, chèn đoạn, thay thế nội dung). Voicebox có ý nghĩa phương pháp vì cho thấy flow-matching có thể học động lực sinh âm thanh hiệu quả, đồng thời mở rộng phạm vi vượt ra ngoài TTS thuần túy.[16]
- Li, Y. A., Han, C., Raghavan, V. S. và cộng sự (2023). *StyleTTS 2: Towards Human-Level Expressive Text-to-Speech with Style Diffusion and Adversarial Training*. StyleTTS 2 nổi bật ở mục tiêu expressive TTS: mô hình hóa phong cách/biểu cảm trong không gian tiềm ẩn và dùng style diffusion để sinh biến thiên ngữ điệu giàu cảm xúc. Điểm mạnh là cơ chế tách nội dung (linguistic content) và style (prosody/emotion) rõ ràng hơn, giúp điều khiển biểu cảm tốt mà không làm méo nội dung. Công trình này đặc biệt liên quan trực tiếp tới bài toán của bạn vì nhấn mạnh rằng chất lượng TTS hiện đại không chỉ nằm ở “đúng chữ” mà còn ở “đúng cách nói”. [17]
- Zhang, X., Zhang, D., Li, S. và cộng sự (2023). *SpeechTokenizer: Unified Speech Tokenizer for Speech Large Language Models*. SpeechTokenizer đóng vai trò nền tảng cho hướng Speech-LM bằng cách rời rạc hóa tín hiệu âm thanh thành các token có cấu trúc (thường tách semantic và acoustic), giúp huấn luyện mô hình ngôn ngữ trên chuỗi mã âm thanh tương tự như LM trên văn bản. Điểm nổi bật là ý tưởng “token hóa lời nói” làm cầu nối giữa NLP và speech generation, mở ra khả năng tích hợp LLM với TTS một cách tự nhiên hơn thông qua không gian token/latent có cấu trúc.[18]
- Ju, Z. và cộng sự (2024). *NaturalSpeech 3: Zero-Shot TTS with Factorized Codec and Diffusion Models*. NaturalSpeech 3 nổi bật ở hướng factorization: tách biệt các nhân tố tạo lời nói (speaker, content, prosody) trong codec và diffusion, giúp điều khiển từng thuộc tính rõ ràng hơn trong suy luận. Đóng góp quan trọng là tăng khả năng điều khiển và tổng quát hóa trong zero-shot TTS, đồng thời giảm can nhiễu giữa các thuộc tính (ví dụ: đổi cảm xúc nhưng không đổi người nói). Đây là một minh chứng mạnh cho xu hướng “có cấu trúc hóa điều kiện” trong TTS thế hệ mới.[19]
- Wang, C. và cộng sự (2023). *VALL-E: Neural Codec Language Models are Zero-Shot Speech Synthesizers*. VALL-E là cột mốc quan trọng khi xem TTS như một bài toán language modeling trên chuỗi mã rời rạc của codec, tức mô hình dự đoán token âm thanh tương tự cách GPT dự đoán token văn bản. Điểm nổi bật là khả năng zero-shot voice cloning mạnh mẽ với vài giây tham chiếu, đồng thời duy trì đặc trưng ngữ điệu và âm sắc. Công trình này có ý nghĩa lớn cho hướng LLM-TTS vì nó đặt ra một khung thống nhất: lời nói có thể được sinh như “ngôn ngữ” trong không gian mã, tạo điều kiện tích hợp sâu hơn các tín hiệu ngữ dụng/điều khiển từ LLM.[20]

Các công trình tiêu biểu giai đoạn 2020–2024 cho thấy sự dịch chuyển rõ rệt từ TTS dựa trên attention tự hồi quy sang các kiến trúc phi tự hồi quy và mô hình sinh xác suất (GAN/flow/diffusion/codec). Trong đó, FastSpeech 2 và Glow-TTS đặt nền tảng về căn chỉnh ổn định và điều khiển prosody ở mức tham số; VITS và YourTTS mở rộng năng lực end-to-end và thích nghi giọng nói; các nhánh diffusion (DiffWave, WaveGrad, Grad-TTS) chứng minh chất lượng tái tạo cao nhưng kéo theo chi phí suy luận; còn nhánh codec + diffusion/LM

(NaturalSpeech 2/3, VALL-E, SpeechTokenizer) mở ra hướng zero-shot và điều khiển thuộc tính lời nói theo biểu diễn rời rạc có cấu trúc. Đặc biệt, StyleTTS 2 nhấn mạnh vai trò trung tâm của ngữ điệu và biểu cảm như một trụ cột chất lượng TTS, qua đó củng cố động cơ nghiên cứu của đề tài: khai thác năng lực suy diễn ngữ dụng của LLM để tạo tín hiệu điều khiển ngữ điệu có cấu trúc, giúp mô hình TTS sinh giọng tiếng Việt tự nhiên và giàu biểu cảm hơn.

2.1.2 Điểm mới và khoảng trống trong đề tài

Mặc dù các hệ thống TTS hiện đại đã tiệm cận chất lượng tự nhiên ở nhiều kịch bản, một số thách thức trọng yếu vẫn tồn tại và cần được tiếp tục giải quyết. Trước hết, các kiến trúc dựa trên flow, diffusion hoặc codec thường đòi hỏi chi phí tính toán đáng kể và dẫn đến độ trễ suy luận cao hơn so với các mô hình feed-forward đơn giản, gây hạn chế khi triển khai trong môi trường thời gian thực hoặc trên thiết bị có tài nguyên hạn chế. Bên cạnh đó, đối với tiếng Việt - một ngôn ngữ giàu thanh điệu - việc mô hình hóa đồng thời thanh điệu (tone) và các thành phần ngữ điệu (prosody) vẫn là bài toán khó, do yêu cầu cơ chế căn chỉnh ổn định cùng các tín hiệu điều khiển có độ chính xác cao để duy trì tính nhất quán về cao độ, nhịp điệu và ngắt nghỉ. Cuối cùng, khả năng điều khiển tường minh các yếu tố biểu cảm và phong cách (ví dụ: điểm nhấn, cảm xúc, thái độ phát ngôn) từ tín hiệu đầu vào do LLM sinh ra vẫn còn hạn chế; điều này đặt ra nhu cầu phát triển các biểu diễn điều kiện có cấu trúc hơn cũng như các cơ chế ánh xạ hiệu quả từ tầng ngôn ngữ-ngữ dụng sang các tham số âm học trong quá trình tổng hợp.

Đề tài này đề xuất các định hướng cải tiến: (1) đề xuất 5 quy trình tối ưu hóa xử lý dữ liệu trước khi đưa vào Matcha-TTS; (2) thiết kế Prosody Encoder đa thang (Multi-scale Prosody Encoder) hoặc Latent Prosody Encoder để trích xuất và tích hợp các tín hiệu prosody phức tạp do LLM suy diễn vào mô hình TTS.

2.2 Tổng quan lý thuyết

2.2.1 Matcha-TTS

Tổng quan về Matcha-TTS

Matcha-TTS là một mô hình tổng hợp tiếng nói (Text-to-Speech) hiện đại, được thiết kế như một kiến trúc encoder-decoder nhanh, phi tự hồi quy và mang tính xác suất, sử dụng Optimal-Transport Conditional Flow Matching (OT-CFM) cho phần acoustic modelling. Thay vì huấn luyện dựa trên score matching như các mô hình diffusion probabilistic models (DPMs) truyền thống, Matcha-TTS học trực tiếp một trường vector điều kiện để sinh mel-spectrogram thông qua một ODE duy nhất, với số bước suy luận ít hơn đáng kể.

Hai đóng góp chính được nêu trong bài báo gốc là: (i) đề xuất decoder dạng U-Net một chiều (1D U-Net) kết hợp 1D CNN và Transformer nhằm giảm footprint bộ nhớ và tăng tốc độ suy luận; và (ii) tối ưu bằng OT-CFM để đạt chất lượng suy luận tốt với số bước lấy mẫu ít hơn so với diffusion thông thường.

Mặc dù có thiết kế gọn nhẹ và tốc độ cao, Matcha-TTS vẫn duy trì các đặc tính quan trọng của một mô hình phi tự hồi quy (non-autoregressive), mang tính xác suất (probabilistic) và có khả năng tự học căn chỉnh (alignment) mà không cần sử dụng aligner bên ngoài. Khi được so sánh với các baseline mạnh đã huấn luyện sẵn, Matcha-TTS cho thấy footprint bộ nhớ nhỏ nhất, tốc độ sinh mẫu tiệm cận mô hình nhanh nhất trong các câu dài, đồng thời đạt Mean Opinion Score (MOS) cao nhất trong các thí nghiệm đánh giá cảm nhận thông qua nghe.

So sánh giữa Matcha-TTS và Voicebox

Voicebox (Meta, 2023) là một trong những mô hình tiên phong áp dụng Flow Matching cho tín hiệu âm thanh; tuy nhiên, thiết kế của Voicebox hướng tới thiết lập đa nhiệm, bao gồm các tác vụ như inpainting, chỉnh sửa (editing) và tổng hợp tiếng nói, thay vì tối ưu hóa riêng cho TTS. Ngược lại, Matcha-TTS tập trung hoàn toàn vào bài toán tổng hợp tiếng nói, nhờ đó có thể tinh chỉnh kiến trúc và mục tiêu học theo hướng chuyên biệt cho chất lượng giọng

đọc và hiệu năng suy luận. Về phương pháp huấn luyện, Voicebox sử dụng Masked-Conditional Flow Matching nhằm khai thác cơ chế che (masking) để phục vụ các tác vụ biên tập và khôi phục tín hiệu, trong khi Matcha-TTS áp dụng OT-CFM (Optimal-Transport Conditional Flow Matching) theo hướng thuần túy hơn. Cách tiếp cận OT-CFM giúp đặc tả đường đi từ phân phối nguồn đến phân phối dữ liệu một cách có cấu trúc và đơn giản, từ đó thường mang lại quá trình huấn luyện ổn định hơn trong bối cảnh tối ưu hóa cho nhiệm vụ TTS.

Đặc điểm	Voicebox	Matcha-TTS
Loại mô hình	Đa nhiệm	TTS thuần túy
Phương pháp	Masked CFM	OT-CFM
Căn chỉnh	Cần aligner	Không cần aligner
Kích thước	$\sim 330\text{M}$ tham số	Nhỏ hơn $\sim 18\times$
Công nghệ	Convolution + AliBi	Transformer + RoPE

Matcha-TTS nhẹ hơn, dễ huấn luyện hơn và hiệu quả hơn cho bài toán tổng hợp tiếng nói tự nhiên.

Mô hình diffusion và Probability Flow ODE

Các diffusion probabilistic models (DPMs) hiện đang thiết lập chuẩn mới trong sinh dữ liệu liên tục, bao gồm ảnh, chuyển động và tổng hợp tiếng nói. Ý tưởng chung là định nghĩa một quá trình diffusion biến phân phối dữ liệu phức tạp thành một phân phối nguồn đơn giản (thường là Gaussian), sau đó học quá trình đảo ngược (reverse) để từ nhiều quay lại dữ liệu.

Khung toán học cho các DPM này thường được mô tả bằng stochastic differential equations (SDEs). Mỗi SDE thuận (forward) lại có một probability flow ODE tương ứng, mô tả cùng một quá trình chuyển phân phối nhưng theo cách deterministic. Probability flow ODE giống với continuous-time normalising flows (CNF), nhưng không yêu cầu backpropagate qua bộ giải ODE đắt đỏ, và không cần xấp xỉ ODE ngược.

Huấn luyện DPMs truyền thống dựa trên score matching: xấp xỉ đạo hàm theo không gian của log-mật độ (score function) thông qua một hàm mất mát MSE có thể liên hệ với ELBO. Cách này cho phép huấn luyện hiệu quả mà không cần giải SDE/ODE trong quá trình train, nhưng có nhược điểm là suy luận chậm vì cần rất nhiều bước (iterations) để giải SDE/ODE, mỗi bước đều phải chạy toàn bộ mạng.

Matcha-TTS giải quyết vấn đề này bằng cách sử dụng flow matching và cụ thể là OT-CFM để học ODE cho tổng hợp.

Flow Matching

Flow matching mô hình hóa một trường vector v_t sinh ra một flow ϕ_t qua phương trình vi phân:

$$\frac{d}{dt} \phi_t(x) = v_t(\phi_t(x)), \quad \phi_0(x) = x, \quad (1)$$

trong đó $x \in \mathbb{R}^d$ là mẫu từ không gian dữ liệu, và $t \in [0, 1]$ tham số hóa đường đi từ phân phối nguồn p_0 (ví dụ Gaussian) tới phân phối đích $p_1 \approx q(x)$ (phân phối dữ liệu). Nếu biết vector field thật u_t sinh ra đường đi p_t , ta có thể học v_t bằng hàm mất mát:

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t, p_t(x)} \|u_t(x) - v_t(x; \theta)\|^2. \quad (2)$$

Optimal-Transport Conditional Flow Matching (OT-CFM)

OT-CFM là một biến thể đặc biệt của CFM, trong đó đường đi giữa x_0 và x_1 được chọn sao cho gần với đường vận chuyển tối ưu trong nghĩa của optimal transport. Đường đi này có dạng nội suy tuyến tính:


$$\phi_t^{\text{OT}}(x_0, x_1) = (1 - (1 - \sigma_{\min})t) x_0 + t x_1, \quad (3)$$

với $\sigma_{\min}$ là một siêu tham số nhỏ (ví dụ 10^{-4}). Trường vector điều kiện tương ứng:

$$u_t^{\text{OT}}(\phi_t^{\text{OT}}(x_0, x_1) | x_1) = x_1 - (1 - \sigma_{\min}) x_0, \quad (4)$$

Là tuyến tính, không phụ thuộc t , và chỉ phụ thuộc vào cặp (x_0, x_1) . Nhờ tính đơn giản này, OT-CFM cho phép huấn luyện nhanh hơn và giúp ODE có thể được giải chính xác chỉ với vài bước rời rạc hoá.

Kiến trúc encoder-decoder trong Matcha-TTS




Hình 1: Kiến trúc tổng quan của Matcha-TTS

Matcha-TTS sử dụng kiến trúc encoder-decoder phi tự hồi quy cho TTS, với sơ đồ tổng quát như Hình 1. Encoder văn bản và bộ dự đoán độ dài (duration predictor) trong Matcha-TTS được thiết kế theo hướng kế thừa các ý tưởng cốt lõi từ Grad-TTS và Glow-TTS, trong đó bộ mã hóa văn bản được xây dựng dựa trên các khối Transformer nhằm trích xuất biểu diễn ngữ cảnh giàu thông tin từ chuỗi âm vị. Khác với cách sử dụng positional encoding tương đối thường gặp, Matcha-TTS áp dụng Rotary Position Embedding (RoPE) để mã hóa thông tin vị trí, qua đó cải thiện khả năng tổng quát hóa trên các chuỗi dài đồng thời giảm chi phí bộ nhớ trong quá trình huấn luyện và suy luận. Quan hệ căn chỉnh giữa chuỗi âm vị và chuỗi khung âm thanh được học thông qua Monotonic Alignment Search (MAS) kết hợp với prior loss, giúp đảm bảo tính đơn điệu và hợp lý của quá trình căn chỉnh theo trục thời gian. Trên cơ sở alignment thu được, duration predictor được huấn luyện để ước lượng độ dài (tương ứng số lượng frame) cho từng âm vị; các vector ẩn đầu ra từ encoder sau đó được mở rộng theo thời lượng dự đoán (upsampling theo duration) để tạo ra μ , tức giá trị trung bình có điều kiện đóng vai trò làm tín hiệu điều khiển cho các khung đặc trưng âm học (mel-spectrogram) ở các bước sinh tiếp theo.

Khác với một số mô hình sinh dữ liệu dựa trên ODE khác, trong Matcha-TTS, μ không được dùng làm mean cho nhiều khối tạo x_0 ; nhiều vẫn được lấy từ phân phối Gaussian chuẩn, còn μ được dùng làm điều kiện cho decoder.

Decoder Matcha-TTS: Mạng dự đoán flow



Hình 2: Decoder của Matcha-TTS

Decoder của Matcha-TTS (Hình 2) được hiện thực dưới dạng một U-Net 1D được tối ưu hóa riêng cho bài toán chuyển văn bản thành giọng nói. Kiến trúc này khai thác các khối ResNet1D kết hợp với phép tích chập một chiều (1D convolution) nhằm trích xuất và tinh lọc đặc trưng theo trục thời gian của chuỗi âm học. Ở mỗi mức độ phân giải của U-Net, bao gồm nhánh giảm mẫu (downsampling), tầng trung gian (mid) và nhánh tăng mẫu (upsampling), các Transformer blocks được chen xen kẽ để tăng cường khả năng mô hình hóa phụ thuộc dài hạn và ngữ cảnh toàn cục, từ đó hỗ trợ cho tính cục bộ của tích chập. Trong toàn bộ quá trình giải mã, decoder được điều kiện hóa bởi embedding của timestep $t \in [0, 1]$ cùng với giá trị trung bình có điều kiện theo văn bản μ được sinh từ encoder, qua đó cho phép mô hình điều chỉnh động học sinh theo thời gian và ràng buộc đầu ra bám sát nội dung ngữ âm đầu vào.

Downsampling blocks: trong pha downsampling, các khối ResNet1D và Transformer giảm dần độ dài chuỗi (downsample), tăng chiều trừu tượng của đặc trưng và nắm bắt phụ thuộc dài hạn nhờ self-attention.

Mid blocks: các mid-block hoạt động ở độ phân giải thấp nhất, kết hợp thông tin từ nhiều x_0 , điều kiện μ và timestep embedding t , để học nên trường vector v_t trong không gian ẩn.

Upsampling blocks: các khối upsampling đảo ngược quá trình downsampling, tăng dần độ dài chuỗi trở lại, kết hợp skip-connections từ các mức downsampling và phục hồi chi tiết mel-spectrogram.

Toàn bộ U-Net 1D này xuất ra trường vector $v_t(\phi_t(x_0) | \mu)$, dùng trong nghiệm ODE để cập nhật trạng thái từ nhiều tới mel-spectrogram.

Snake-beta activations: tất cả feed-forward network trong các Transformer block của decoder sử dụng snake beta activation (lấy cảm hứng từ BigVGAN), vốn được chứng minh hiệu quả trong việc biểu diễn tín hiệu có cấu trúc dao động, giúp mel-spectrogram mượt hơn và nhiều chi tiết hài hòa hơn so với ReLU hoặc GELU.

Không dùng positional encoding trong decoder: decoder không sử dụng positional encoding riêng, vì vị trí đã được mã hóa gián tiếp bởi encoder và duration; các phép convolution cùng downsampling/upsampling đã nắm bắt thông tin vị trí tương đối trên trục thời gian.

Nhờ thiết kế U-Net 1D này, decoder của Matcha-TTS nhanh hơn và tiết kiệm bộ nhớ hơn U-Net 2D trong Grad-TTS, nơi mel-spectrogram được coi là ảnh 2D.

2.2.2 Mô hình ngôn ngữ lớn (Large Language Models – LLMs)

Tổng quan về LLMs

Các mô hình ngôn ngữ lớn (LLMs) là thể hệ mô hình học sâu hiện đại dựa trên kiến trúc Transformer, được huấn luyện trên khối lượng dữ liệu văn bản rất lớn để học các quy luật thống kê của ngôn ngữ. Nhờ khả năng mô hình hóa phụ thuộc dài hạn, các LLM có thể xử lý đa dạng nhiệm vụ như phân tích ngữ nghĩa, sinh văn bản, suy luận và dịch thuật.

Trong hệ thống LLM–TTS, LLM đóng vai trò phân tích ngữ nghĩa, xác định cấu trúc câu và sinh ra các tín hiệu điều kiện như ngữ điệu, trọng âm hoặc các thẻ prosody. Đây là bước quan trọng để nâng cao chất lượng giọng nói và khả năng biểu đạt của hệ thống tổng hợp tiếng nói.

Kiến trúc Transformer

Hầu hết các LLM hiện đại như GPT, BERT, LLaMA hay PaLM đều dựa trên kiến trúc Transformer. Transformer loại bỏ hoàn toàn tính tuần tự của RNN hoặc LSTM và thay thế bằng cơ chế tự chú ý (self-attention), cho phép mô hình xem xét toàn bộ câu trong một lần tính toán. Cơ chế self-attention cho phép mỗi token trong câu tính toán mức độ liên quan với các token khác thông qua ba ma trận đặc trưng: Query (Q), Key (K) và Value (V). Trọng số chú ý được xác định bằng:

$$\text{Attention}(Q, K, V) = \text{Softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

nhằm trích xuất bối cảnh ngữ nghĩa toàn cục.

Quá trình học mô hình ngôn ngữ

LLM được huấn luyện bằng cách dự đoán token tiếp theo trong chuỗi văn bản. Bản chất của LLM là mô hình hóa phân phối xác suất:

$$P(x_1, x_2, \dots, x_n) = \prod_{t=1}^n P(x_t | x_{<t})$$

nhờ đó có khả năng sinh văn bản trôi chảy, logic và có tính mạch lạc cao.

Vai trò của LLM trong hệ thống LLM–TTS

Trong một pipeline tích hợp giữa LLM và TTS, mô hình ngôn ngữ lớn (LLM) đóng vai trò tạo sinh các tín hiệu điều khiển ngữ điệu theo dạng có cấu trúc, nhằm cung cấp thông tin điều kiện ở mức ngôn ngữ–ngữ dụng cho mô-đun tổng hợp tiếng nói. Cụ thể, LLM có thể phân tích quan hệ Given–New Information để nhận diện các thành phần mang thông tin mới và từ đó xác định trọng tâm nhấn ngữ nghĩa phù hợp. Đồng thời, thông qua phân tích cú pháp và cấu trúc câu, LLM suy ra các vị trí ngắt nghỉ tự nhiên cũng như ước lượng độ dài khoảng dừng tương ứng, giúp cải thiện tính mạch lạc của nhịp điệu lời nói. Bên cạnh đó, mô hình còn thực hiện suy diễn ngữ cảnh, trạng thái cảm xúc và mục đích phát ngôn (intent) để lựa chọn phong cách giọng đọc nhất quán với nội dung. Trên cơ sở các phân tích này, LLM gán các thẻ điều kiện dưới dạng prosody tags hoặc SSML nhằm điều khiển trực tiếp các thuộc tính âm học quan trọng như pitch, energy và duration trong quá trình sinh mel-spectrogram và/hoặc điều khiển vocoder ở bước tổng hợp cuối.

Embeddings và mã hóa vị trí

Token được ánh xạ vào không gian vector liên tục thông qua các lớp từ vệt nhúng (embeddings) nhằm biểu diễn thông tin ngữ nghĩa dưới dạng đặc trưng số. Tuy nhiên, do kiến trúc Transformer không sở hữu tính tuần tự nội tại như RNN, mô hình cần được cung cấp thông tin về thứ tự và vị trí của token trong chuỗi thông qua các cơ chế mã hóa vị trí (positional encoding). Trong thực tiễn, các hướng tiếp cận phổ biến bao gồm: (i) *Sinusoidal Positional*

Encoding; (ii) *Relative Position Encoding* như trong Transformer-XL hoặc T5; và (iii) *Rotary Position Embedding (RoPE)*, được áp dụng trong nhiều kiến trúc hiện đại như GPT-J, LLaMA và encoder của Matcha-TTS. Đáng chú ý, RoPE thể hiện hiệu quả rõ rệt trong các mô hình quy mô lớn nhờ khả năng tổng quát hóa tốt khi mở rộng độ dài ngữ cảnh, qua đó hỗ trợ xử lý các chuỗi dài ổn định hơn so với nhiều biến thể mã hóa vị trí khác.

3 Phương pháp đề xuất

Sự phát triển của các hệ thống tổng hợp tiếng nói thế hệ mới như Matcha-TTS cho thấy tiềm năng lớn trong việc tạo ra giọng nói tự nhiên và giàu cảm xúc. Tuy nhiên, chất lượng đầu ra phụ thuộc mạnh mẽ vào bộ dữ liệu huấn luyện, đặc biệt đối với tiếng Việt – một ngôn ngữ được xem là ít tài nguyên trong xử lý tiếng nói.


Nguồn dữ liệu phòng thu chất lượng cao vừa khan hiếm vừa tốn kém, trong khi dữ liệu *in-the-wild* (podcast, audiobook, video) thì phong phú nhưng chứa nhiều nhiễu, nhạc nền và thiếu bản ghi văn bản. Chương này đề xuất một phương pháp 5 giai đoạn nhằm chuyển đổi dữ liệu *in-the-wild* thành bộ dữ liệu sạch, chuẩn hóa và sẵn sàng cho huấn luyện TTS.

3.1 Bối cảnh

Một bộ dữ liệu TTS chất lượng cao cần đáp ứng: (1) âm thanh sạch; (2) transcript chính xác; (3) văn bản đã được chuẩn hóa; và (4) giọng hàng thời gian chính xác. Hầu hết các bộ dữ liệu tiếng Việt hiện có như VIVOS hoặc Common Voice không đáp ứng đủ tiêu chuẩn để huấn luyện TTS hiện đại, dẫn đến nhu cầu xây dựng một pipeline xử lý dữ liệu tự động và hiệu quả.


3.2 Tổng quan pipeline đề xuất

Pipeline tổng quát cho cả quá trình được mô tả trong Hình 3.



Hình 3: Pipeline huấn luyện và suy luận với các thành phần cải tiến được tô xám.

Pipeline xử lý dữ liệu được mô tả trong Hình 4.



Hình 4: Pipeline 5 giai đoạn xử lý dữ liệu *in-the-wild* cho huấn luyện Matcha-TTS.

Pipeline tổng quát của hệ thống, bao gồm cả pha huấn luyện và pha suy luận, được minh họa trong Hình 3. Trọng tâm của nghiên cứu là tích hợp các thành phần phân tích prosody dựa trên LLM vào Matcha-TTS nhằm cải thiện độ tự nhiên của giọng đọc, trong khi vẫn đảm bảo tính ổn định khi huấn luyện trên dữ liệu *in-the-wild*. Các thành phần cải tiến được tô xám trong hình.

Pha huấn luyện.

Trong pha huấn luyện, dữ liệu âm thanh *in-the-wild* được xử lý qua pipeline 5 giai đoạn (Hình 4), bao gồm phát hiện đoạn có tiếng nói, tách giọng, phiên âm, sửa lỗi và chuẩn hóa văn bản, nhằm tạo ra các cặp (audio, text) sạch và giống hàng tốt. Song song với nhánh Text Encoder chuẩn của Matcha-TTS, văn bản đã chuẩn hóa cũng được đưa vào mô-đun phân tích prosody dựa trên LLM để suy diễn các tín hiệu ngữ điệu ở mức câu. Sau bước Prosody Fusion

& Conditioning, đặc trưng hợp nhất được dùng để sinh điều kiện μ cho decoder OT-CFM, cho phép mô hình học mel-spectrogram vừa đúng nội dung ngôn ngữ, vừa phản ánh nhịp điệu và trọng âm phù hợp với ngữ cảnh.

Pha suy luận.

Trong pha suy luận, quy trình xử lý văn bản được giữ nhất quán với pha huấn luyện. Văn bản đầu vào được đồng thời đưa qua Text Encoder của Matcha-TTS và mô-đun LLM Prosody Analysis, sau đó hợp nhất thông qua Prosody Fusion & Conditioning để tạo điều kiện μ cho decoder. Thiết kế này cho phép sinh giọng đọc có nhấn nhá và ngắt nghỉ tự nhiên hơn mà không cần thay đổi vocoder hay cấu trúc decoder, đảm bảo khả năng tái sử dụng mô hình và triển khai linh hoạt.

3.3 Đề xuất cải tiến

3.3.1 Đề xuất 5 giai đoạn tối ưu hóa quy trình xử lý dữ liệu

Giai đoạn 1: Phát hiện hoạt động giọng nói (VAD)

Giai đoạn đầu tiên là sàng lọc, loại bỏ các khoảng lặng hoặc các đoạn chỉ chứa tiếng ồn/âm nhạc, chỉ giữ lại các phân đoạn có chứa giọng nói của con người. Các thuật toán VAD dựa trên năng lượng, ZCR hoặc MFCC rất dễ nhầm lẫn trong môi trường nhiễu mạnh, gây cắt mất âm đầu/cuối hoặc nhận nhầm tiếng ồn thành giọng nói.

Phương pháp đề xuất sử dụng Silero-VAD, là mô hình deep learning nhẹ, chạy nhanh, huấn luyện trên hàng nghìn ngôn ngữ và hoạt động tốt ngay cả trong môi trường nhiễu mạnh. Mô hình trả về xác suất chứa giọng nói thay vì ngưỡng năng lượng. Silero-VAD đóng vai trò bộ lọc thông minh, giúp tránh lãng phí tài nguyên GPU cho các mô hình nặng như Demucs hoặc Whisper.

Giai đoạn 2: Tách nguồn âm (Source Separation)

Các kỹ thuật Spectral Subtraction hoặc Wiener Filtering chỉ xử lý biên độ, làm mất pha và tạo artifact metallic/robotic. Khi nhiễu là nhạc nền, các phương pháp này gần như vô hiệu.

Phương pháp đề xuất sử dụng Demucs, một mô hình học sâu end-to-end cho việc tách nguồn âm (Audio Source Separation). Demucs hoạt động trực tiếp trên waveform, giữ nguyên pha và tái tạo giọng nói chất lượng cao nhờ kiến trúc U-Net + BiLSTM, giúp lọc được cả nhiễu là âm nhạc. Quy trình chỉ giữ lại nguồn vocals cho mục tiêu chuẩn bị dữ liệu TTS.


Giai đoạn 3: Phân đoạn và phiên âm bằng Whisper

Đây là giai đoạn nền tảng trong việc xây dựng bộ dữ liệu huấn luyện cho Matcha-TTS, nơi tín hiệu âm thanh sạch được phân tách thành các đoạn ngắn và gán nhãn văn bản tương ứng. Khác với Montreal Forced Aligner (MFA) yêu cầu transcript chính xác tuyệt đối, phương pháp sử dụng Whisper cho phép tự động hóa và mở rộng dữ liệu mà không cần văn bản chuẩn bị trước. Quy trình sử dụng Whisper, một mô hình nhận dạng tiếng nói tự động (ASR) đa ngôn ngữ quy mô lớn, để giải quyết bài toán thiếu hụt nhãn dữ liệu. Mô hình tiếp nhận đầu vào là các tệp âm thanh sạch đã được tách nguồn từ Demucs và thực hiện đồng thời hai nhiệm vụ: chuyển đổi tín hiệu âm thanh thành văn bản phiên âm thô và xác định các mốc thời gian (timestamps) tương ứng. Dựa trên các mốc thời gian này, hệ thống tự động cắt tệp âm thanh thành các phân đoạn có độ dài vài giây, đảm bảo tính trọn vẹn về mặt ngữ nghĩa và âm học.

Giai đoạn 4: Hậu xử lý văn bản (Hybrid Text Processing)

Các hệ thống TN thuần luật không hiểu ngữ cảnh, không sửa được lỗi ASR và dễ sai khi gặp ngày tháng hoặc số nhiều nghĩa. Văn bản thô thường chứa hai loại lỗi: (i) lỗi ngữ nghĩa/ngữ cảnh (ASR errors) và (ii) lỗi không chuẩn hóa (Normalization errors). Phương pháp đề xuất sử dụng cách tiếp cận hybrid để xử lý cả hai.

Giai đoạn đầu, văn bản thô từ Whisper được đưa vào LLM tiếng Việt (PhoGPT) để hiệu chỉnh ngữ nghĩa, chính tả và ngữ pháp, đặc biệt sửa các lỗi đồng âm hoặc cụm từ bất hợp lý



Hình 5: Sơ đồ Demucs.

dựa trên ngữ cảnh. Giai đoạn hai, văn bản đã hợp thức hóa ngữ nghĩa được chuẩn hóa theo luật (rule-based) để xử lý NSW, sử dụng `num2words`, `regex`, `underthesea` và `espeak-ng`. Cách tiếp cận này tận dụng khả năng suy luận linh hoạt của LLM và tính chính xác tất định của luật chuẩn hóa.


Giai đoạn 5: Phân tích kỹ thuật – Resampling

Quy trình xử lý âm thanh được thiết kế đa tần số lấy mẫu (multi-sample rate) nhằm đáp ứng đặc tả đầu vào của từng mô hình: VAD/Whisper ở 16 kHz, Demucs ở 44.1 kHz và đầu ra TTS ở 22.05 kHz. Chiến lược resampling sử dụng nội suy chất lượng cao để giảm aliasing và đảm bảo tính toàn vẹn của tín hiệu qua từng giai đoạn.

3.3.2 Kết hợp LLM-based Prosody Conditioning cho tiếng Việt

Các giai đoạn 1–5 ở trên tập trung vào *chuẩn hóa dữ liệu* để huấn luyện TTS ổn định trên nguồn *in-the-wild*. Tuy nhiên, ngay cả khi dữ liệu đã sạch và giống hàng tốt, giọng đọc tổng hợp vẫn có thể thiếu tự nhiên nếu mô hình không được cung cấp tín hiệu điều kiện ở mức *ngữ nghĩa-ngữ dụng* (pragmatics-level). Vấn đề này đặc biệt rõ ở tiếng Việt: bên cạnh *thanh điệu từ vựng* (lexical tone), ngữ điệu câu (intonation), trọng tâm thông tin và nhịp ngắt nghỉ theo cú pháp góp phần quyết định cảm giác “giống người” của giọng đọc.

Để khắc phục, nghiên cứu đề xuất tích hợp LLM theo hướng suy diễn prosody có cấu trúc và truyền tín hiệu này vào Matcha-TTS như một nhánh *conditioning* bổ sung. Khác với phần LLM dùng cho *hậu xử lý văn bản* ở Giai đoạn 4 (sửa lỗi/chuẩn hóa transcript), phần cải tiến ở mục này tập trung vào LLM cho phân tích prosody khi huấn luyện và suy luận TTS.



Hình 6: Prosody Encoder dựa trên PhoBERT.

Như minh họa trong Hình 6, mô-đun Prosody Encoder được thiết kế nhằm trích xuất biểu diễn ngữ nghĩa ở mức câu để làm tín hiệu điều kiện prosody cho mô hình TTS. Văn bản tiếng Việt sau khi được chuẩn hóa sẽ được đưa vào PhoBERT encoder với trọng số cố định (*frozen weights*), giúp tận dụng tri thức ngôn ngữ đã được huấn luyện trước mà không làm gia tăng độ phức tạp huấn luyện tổng thể.

Vector biểu diễn tại vị trí [CLS] (768 chiều) được sử dụng như một embedding tóm lược thông tin ngữ nghĩa-ngữ dụng toàn câu, bao gồm cấu trúc cú pháp, trọng tâm thông tin và ngữ cảnh diễn đạt. Cách tiếp cận này phù hợp với mục tiêu mô hình hóa prosody ở mức câu (*sentence-level prosody*), thay vì phụ thuộc hoàn toàn vào đặc trưng âm học cục bộ.

Do sự khác biệt về không gian biểu diễn giữa embedding ngôn ngữ và không gian latent của mô hình TTS, một lớp chiếu tuyến tính được sử dụng để ánh xạ vector [CLS] từ 768 chiều xuống không gian 256 chiều. Kết quả thu được là vector prosody tiềm ẩn z_p , đóng vai trò như tín hiệu điều kiện ngữ nghĩa cho các khối encoder và duration predictor trong Matcha-TTS.

Thiết kế này cho phép mô hình TTS tiếp nhận thông tin prosody ở mức trừu tượng, hỗ trợ tái tạo ngữ điệu, nhịp điệu và trọng âm câu phù hợp với ngữ cảnh tiếng Việt, trong khi vẫn giữ được tính ổn định khi huấn luyện trên dữ liệu *in-the-wild*. Khác với các phương pháp dựa thuần túy vào đặc trưng âm học hoặc nhân prosody thủ công, hướng tiếp cận đề xuất cho phép suy diễn prosody trực tiếp từ ngữ nghĩa văn bản, phù hợp với các kịch bản tổng hợp giọng nói có nội dung dài, đa dạng và khó gán nhãn prosody một cách tường minh.

3.3.3 Prosody Fusion & Conditioning trong Matcha-TTS

Vector prosody tiềm ẩn z_p thu được từ Prosody Encoder được sử dụng như một tín hiệu điều kiện bổ sung trong quá trình huấn luyện và suy luận của Matcha-TTS. Cụ thể, z_p được broadcast theo chiều thời gian và kết hợp với biểu diễn ẩn của encoder văn bản thông qua phép nối (*concatenation*) hoặc phép cộng sau khi chiếu tuyến tính về cùng không gian đặc trưng. Nhờ đó, thông tin prosody ở mức câu có thể tác động xuyên suốt lên các khối dự đoán thời lượng và sinh đặc trưng âm học.

Trong Matcha-TTS, duration predictor đóng vai trò quyết định đối với nhịp điệu và phân bố thời gian phát âm của từng đơn vị ngôn ngữ. Việc điều kiện hóa duration predictor bằng z_p giúp mô hình học được các quy luật ngữ điệu ở cấp độ câu, chẳng hạn như kéo dài tại vị trí trọng tâm thông tin, thay đổi nhịp đọc theo cấu trúc cú pháp, hoặc điều chỉnh mẫu ngắt nghỉ tương ứng với ngữ cảnh diễn đạt. Bên cạnh đó, khi z_p được đưa vào các khối sinh biểu diễn trung gian, mô hình có thêm “prior” ngữ nghĩa để tái tạo đường cong ngữ điệu (*intonation contour*) và mức nhấn (*emphasis*) nhất quán hơn trên các câu dài.

Lý do sử dụng embedding [CLS] thay vì token-level prosody.

Nghiên cứu lựa chọn embedding tại vị trí [CLS] của PhoBERT để biểu diễn prosody ở mức câu, thay vì khai thác đặc trưng theo từng token, dựa trên ba lý do chính. (i) Mục tiêu của mô-đun prosody là mô hình hóa ngữ điệu và nhịp điệu ở cấp độ câu (*sentence-level prosody*), không tập trung vào các biến thiên vi mô (*micro-prosody*) theo từng âm vị. (ii) Embedding [CLS] thường là biểu diễn hiệu quả cho ngữ nghĩa toàn câu trong nhiều tác vụ NLP, phù hợp để tóm lược tín hiệu ngữ nghĩa-ngữ dụng phục vụ điều kiện hóa prosody. (iii) Việc sử dụng một vector prosody duy nhất giúp giảm độ phức tạp khi tích hợp với Matcha-TTS, đảm bảo tính ổn định khi huấn luyện và hạn chế chi phí tính toán trong pha suy luận.


3.3.4 Prosody Fusion (Cross-Attention + Gating)

Để tích hợp tín hiệu prosody vào biểu diễn âm vị mà không gây nhiễu nội dung, nghiên cứu đề xuất mô-đun *Prosody Fusion* gồm: Cross-Attention và Gating. Cross-Attention cho phép Text Encoder “chú ý” tới tín hiệu prosody tại các vị trí quan trọng, trong khi gating đóng vai trò điều khiển thích nghi, giúp mô hình tự quyết định mức ảnh hưởng của prosody (giảm nguy cơ over-conditioning ở các câu trung tính).

Gọi $H \in \mathbb{R}^{T \times d}$ là đặc trưng từ Text Encoder và $P \in \mathbb{R}^{T \times d}$ là đặc trưng prosody đã được align theo thời gian. Một dạng hợp nhất đơn giản có thể viết:

$$A = \text{Attn}(H, P, P), \quad g = \sigma(W_g[H; A] + b_g), \quad \tilde{H} = H + g \odot A, \quad (5)$$

trong đó $\sigma(\cdot)$ là sigmoid và $\odot$ là phép nhân theo phần tử. $\tilde{H}$ được dùng để sinh điều kiện μ cho decoder OT-CFM.



Hình 7: Prosody Fusion: kết hợp đặc trưng Text Encoder với prosody từ LLM bằng Cross-Attention và gating để tạo điều kiện μ cho decoder Matcha-TTS.

Như minh họa trong Hình 7, mô-đun *Prosody Fusion* được thiết kế để tích hợp tín hiệu prosody suy diễn từ LLM vào biểu diễn âm vị của Text Encoder một cách *có kiểm soát*, nhằm cải thiện ngữ điệu và trọng âm nhưng không làm suy giảm nội dung phát âm. Cốt lõi của mô-đun gồm hai thành phần: (i) *Cross-Attention* để lựa chọn vị trí cần nhấn/điều chỉnh trong chuỗi âm vị, và (ii) *Gating* để điều tiết mức độ ảnh hưởng của prosody theo ngữ cảnh, qua đó hạn chế hiện tượng *over-conditioning* ở các câu trung tính.

Cụ thể, với $H \in \mathbb{R}^{T \times d}$ là đặc trưng âm vị từ Text Encoder và $P \in \mathbb{R}^{T \times d}$ là đặc trưng prosody đã được giống hàng theo thời gian, Cross-Attention tạo ra ngữ cảnh prosody $A =$

$\text{Attn}(H, P, P)$ (xem (5)) để mô hình “truy vấn” (query) theo nội dung âm vị và “lấy” (key/value) thông tin prosody tương ứng. Nhờ cơ chế này, prosody không được cộng đồng đều lên toàn chuỗi, mà được phân bổ có chọn lọc vào các vị trí mang tính chức năng như trọng tâm câu, biên cú pháp, hoặc những cụm cần nhấn mạnh.

Tuy nhiên, chỉ dùng attention có thể khiến prosody lẫn át nội dung khi tín hiệu P có nhiều hoặc khi câu không đòi hỏi ngữ điệu đặc biệt. Do đó, nghiên cứu bổ sung cổng điều khiển $g = \sigma(W_g[H; A] + b_g)$ để ước lượng hệ số ảnh hưởng theo từng vị trí và từng chiều đặc trưng. Khi g gần 0, mô hình ưu tiên giữ nguyên biểu diễn nội dung H ; khi g tăng, mô hình cho phép bơm thêm tín hiệu prosody thông qua $\tilde{H} = H + g \odot A$. Thiết kế dạng residual này giúp ổn định huấn luyện và duy trì tính bảo toàn nội dung, đồng thời vẫn cho phép prosody can thiệp đủ mạnh tại các điểm quan trọng.

Sau khi hợp nhất, $\tilde{H}$ được sử dụng để sinh điều kiện μ cho decoder OT-CFM của Matcha-TTS. Về mặt trực giác, μ đóng vai trò “đích” có điều kiện trong không gian đặc trưng, vì vậy việc đưa prosody vào trước bước sinh μ giúp decoder nhận được định hướng ngữ điệu ngay từ đầu, cải thiện độ tự nhiên của nhịp điệu, ngắt nghỉ và trọng âm trong quá trình tổng hợp.

4 Thực nghiệm

4.1 Dữ liệu huấn luyện

Nguồn dữ liệu được xây dựng từ giọng đọc của một nam phát thanh viên, thu thập từ các nguồn công khai trên Internet với tổng thời lượng xấp xỉ 6 tiếng 30 phút (trước khi cắt gọt). Dữ liệu có đặc trưng đọc diễn cảm, ngữ điệu ổn định và phát âm rõ ràng.

Dữ liệu văn bản và dữ liệu âm thanh được công bố kèm theo để phục vụ khả năng tái lập thí nghiệm.¹

Dữ liệu âm thanh

Dữ liệu gốc 16kHz/44.1kHz đã được chuẩn hóa đồng bộ về 22.050 Hz (22.05kHz). Đây là tần số tiêu chuẩn cho các mô hình Neural Vocoder hiện đại (như HiFi-GAN) để cân bằng giữa chất lượng âm thanh và chi phí tính toán. Các đoạn được cắt thành mẫu từ 1-12 giây, loại bỏ khoảng lặng và chuẩn hóa biên độ, mono (đơn kênh).

Dữ liệu văn bản

Văn bản tương ứng được chuẩn hóa theo chính tả, dấu câu và cách viết số. Tất cả các ký hiệu đặc biệt, số, phần trăm hoặc ngày tháng được chuyển đổi sang dạng đọc (verbalized). Văn bản sau đó được chuyển sang dạng phiên âm IPA thông qua *phonemizer* hoặc *espeak-ng* nhằm đảm bảo tính nhất quán giữa chữ viết và âm thanh đầu vào. Dữ liệu được định dạng phân cách bằng ký tự ‘|’ theo chuẩn LJSpeech: filename.wav|transcript|ipa.

```
audio1_0000.wav|Nghĩa bắt tay đề, rồi dục các thành viên lên tàu. Cửa tàu đóng lại.|ŋ ' i ʔ ə 5 b ' a ʒ t _  
t _ ' a j d ' e 2 , z ' o 2 j z ' u 6 c k , a : ʒ c t ' e - 2 ɲ v ' i ʔ ɛ n l ' e n t _ ' a 2 w . k ' y ʔ ə 4  
t _ ' a 2 w d ' ɔ ʒ ɲ l ' a : 6 j .
```

Hình 8: Dữ liệu input

4.2 Độ đo đánh giá

Độ rõ lời (Intelligibility) được đánh giá bằng WER và CER thông qua ASR Whisper. Ngữ điệu (Prosody) được đo bằng F0 RMSE và F0 Correlation dựa trên so sánh đường bao F0. Độ tự nhiên (Naturalness) được ước lượng bằng MOS dự đoán bởi UTMOS.

¹Text data: <https://drive.google.com/drive/folders/1uCEyhGzthdcLaoF8QBC5wjK0stkM3GVk?usp=sharing>. Audio data: https://drive.google.com/drive/folders/1ZuLo0VgOM5zXy7caTN01kFcPtXAJzV9_?usp=sharing.

4.3 Chiến lược phân chia dữ liệu

Để đánh giá khách quan hiệu năng mô hình và kiểm soát hiện tượng quá khớp (overfitting), chúng tôi áp dụng chiến lược phân chia dữ liệu ngẫu nhiên (Random Split) với tỷ lệ 85–10–5. Việc chia dữ liệu được thực hiện cố định (fixed seed) để đảm bảo tính nhất quán giữa các lần chạy thử nghiệm.

Tập dữ liệu	Tỷ lệ	Số lượng mẫu	Vai trò
Training Set	85%	9517 mẫu	Dùng để cập nhật trọng số mô hình thông qua Gradient Descent. Tỷ lệ lớn được ưu tiên do tổng dữ liệu ở mức trung bình, cần tối đa hóa lượng mẫu để mô hình học được các biến thể ngữ âm.
Validation Set	10%	1120 mẫu	Dùng để đánh giá Loss sau mỗi epoch, tinh chỉnh siêu tham số và quyết định dừng sớm (Early Stopping).
Test Set	5%	560 mẫu	Được giữ riêng biệt hoàn toàn, chỉ dùng để đo lường các chỉ số cuối cùng (MOS) sau khi huấn luyện xong.

4.4 Cấu hình huấn luyện

4.4.1 Môi trường huấn luyện

Quá trình thực nghiệm được triển khai trên hệ thống tính toán hiệu năng cao bao gồm 02 GPU NVIDIA Tesla T4, trong đó mỗi thiết bị được trang bị bộ nhớ VRAM 16GB. Để tối ưu hóa tài nguyên và thời gian thực thi, chiến lược huấn luyện phân tán (Distributed Data Parallel – DDP) được áp dụng đồng bộ trên cả hai thẻ đồ họa. Phương pháp này cho phép sao chép mô hình và xử lý song song các phân đoạn dữ liệu khác nhau, không chỉ giúp tăng tốc độ hội tụ mà còn tạo điều kiện thiết lập kích thước lô (batch size) tổng thể lớn hơn. Với dung lượng bộ nhớ 16GB mỗi thẻ, hệ thống đảm bảo đủ không gian lưu trữ cho các vector tham số phức tạp của cả PhoBERT và Matcha-TTS mà không gặp trở ngại về giới hạn bộ nhớ (OOM).

4.4.2 Thông số trích xuất đặc trưng

Các tham số tiền xử lý tín hiệu được thiết lập dựa trên chuẩn mực của các bộ Vocoder hiện đại nhằm đảm bảo chất lượng tái tạo âm thanh tốt nhất. Cụ thể, tín hiệu được xử lý ở tần số lấy mẫu 22050 Hz theo định lý Nyquist, giúp bao phủ trọn vẹn dải tần nghe rõ của giọng nói con người (lên đến 11.025 Hz) mà vẫn đảm bảo hiệu quả lưu trữ. Phép biến đổi STFT sử dụng độ dài cửa sổ (Win Length/N-FFT) là 1024 mẫu và bước nhảy (Hop Length) là 256 mẫu (tương đương 11.6ms); tỷ lệ này được lựa chọn nhằm đạt sự cân bằng tối ưu giữa độ phân giải tần số (để tách biệt các họa âm) và độ phân giải thời gian (để xác định chính xác biên giới các âm vị ngắn). Đặc trưng đầu vào sau đó được nén thành 80 băng tần Mel trong phạm vi 0–8000 Hz, đủ chi tiết để mô hình nắm bắt các cộng hưởng (formants) quan trọng. Cuối cùng, toàn bộ dữ liệu được chuẩn hóa dựa trên thống kê của tập huấn luyện (với `mel-mean` $\approx$ -4.50 và `mel-std` $\approx$ 2.35) nhằm đưa phân phối về dạng chuẩn tắc, hỗ trợ hàm mất mát hội tụ ổn định hơn.

4.4.3 Siêu tham số huấn luyện


Hệ thống siêu tham số (Hyperparameters) được tinh chỉnh kỹ lưỡng để cân bằng giữa giới hạn phần cứng và hiệu năng của kiến trúc mạng tích hợp mô hình ngôn ngữ lớn. Do việc nhúng PhoBERT làm gia tăng đáng kể lượng tham số và yêu cầu bộ nhớ VRAM trong quá trình tính toán (backpropagation), kích thước lô (Batch Size) được thiết lập giới hạn ở mức 4 mẫu trên mỗi GPU (tổng kích thước lô vật lý là 8). Đây là ngưỡng tối đa để đảm bảo hệ thống hoạt động ổn định trên thẻ Tesla T4 16GB mà không gặp lỗi tràn bộ nhớ (OOM). Để bù đắp cho kích

thước lô nhỏ, chu trình huấn luyện được duy trì kéo dài 600 epochs, đảm bảo mô hình thực hiện đủ số bước cập nhật trọng số cần thiết để hội tụ về điểm cực tiểu toàn cục. Về thuật toán tối ưu hóa, nghiên cứu sử dụng AdamW với tốc độ học khởi tạo 1×10^{-4} và cơ chế giảm dần (scheduler), giúp ổn định quá trình huấn luyện dù phương sai của gradient có thể cao hơn do batch size nhỏ. Quy trình xử lý văn bản sử dụng `espeak-ng` cấu hình cho tiếng Việt kết hợp với bộ làm sạch cleaners để chuẩn hóa đầu vào, đảm bảo tính nhất quán dữ liệu.

4.5 Kết quả thực nghiệm


4.5.1 Phân tích sự biến thiên của hàm mất mát theo Epoch (Mở rộng 600 Epoch)

Để đánh giá toàn diện khả năng hội tụ và độ ổn định dài hạn của mô hình Matcha-TTS, nghiên cứu đã mở rộng quá trình huấn luyện lên 600 epoch. Việc theo dõi dữ liệu trong chu kỳ dài giúp quan sát rõ các giai đoạn từ học đặc trưng thô (coarse features) đến tinh chỉnh chi tiết (fine-tuning).




Hình 9: Diễn biến hàm mất mát tổng thể (Total Loss) qua 600 Epochs.

Quan sát đồ thị tại Hình 9, quá trình tối ưu hóa thể hiện xu hướng giảm dần đều từ mức khởi điểm 4.9 và đạt trạng thái bão hòa (saturation) quanh mức **2.75** ở các epoch cuối. Đồ thị cho thấy mô hình không có dấu hiệu bị quá khớp (overfitting) khi loss không bị tăng ngược trở lại dù huấn luyện kéo dài. Giai đoạn từ epoch 400 đến 600, đường cong trở nên rất phẳng, cho thấy mô hình đã học được hầu hết các đặc trưng quan trọng và đang tập trung tối ưu hóa các chi tiết nhỏ nhất.




Hình 10: Diễn biến hàm mất mát mất mát khuếch tán (Diffusion Loss).

Thành phần Diffusion Loss (Hình 10) đóng vai trò quyết định chất lượng âm sắc. Sau giai đoạn giảm sốc ban đầu, chỉ số này đi vào ổn định rất sớm và duy trì dao động nhẹ quanh mức **1.45** trong suốt 400 epoch sau cùng. Việc duy trì training đến 600 epoch dù loss không giảm sâu thêm về mặt con số, nhưng thực tế giúp bộ giải mã (Decoder) "thăm" sâu hơn các chi tiết tần số cao, giúp loại bỏ hiện tượng méo tiếng (artifacts) và làm giọng nói trong trẻo hơn.



Hình 11: Diễn biến hàm mất mát thời lượng (Duration Loss).

Sự cải thiện rõ rệt nhất khi kéo dài huấn luyện nằm ở Duration Loss (Hình 11). So với mốc epoch 200 (loss 0.7), việc huấn luyện đến 600 epoch đã giúp chỉ số này giảm sâu xuống mức 0.3 - 0.35. Dù vẫn còn dao động do tính chất ngẫu nhiên của việc dự báo độ dài, nhưng xu hướng giảm sâu này khẳng định bộ chỉnh hợp (Aligner) đã hoạt động cực kỳ hiệu quả, kiểm soát nhịp điệu đọc chính xác hơn hẳn, khắc phục triệt để tình trạng ngắt nghỉ sai hoặc nuốt âm.




Hình 12: Diễn biến hàm mất mát tiên nghiệm (Prior Loss).

Cuối cùng, Prior Loss (Hình 12) thể hiện đường cong hội tụ mượt mà nhất, giảm từ từ và tiệm cận mức sàn 0.96. Kết quả này phản ánh sự đồng bộ hóa tốt giữa văn bản đầu vào và không gian tiềm ẩn (latent space), đảm bảo ngữ điệu sinh ra tự nhiên và sát với ngữ cảnh.


Tóm lại, việc mở rộng huấn luyện lên 600 epoch đã chứng minh hiệu quả rõ rệt, đặc biệt là ở khả năng kiểm soát thời lượng (Duration) và độ ổn định tổng thể.

4.5.2 Phân tích phổ âm

Để đánh giá chi tiết chất lượng tín hiệu âm thanh và khả năng mô phỏng ngữ điệu, nghiên cứu thực hiện so sánh trực quan phổ Mel (Mel-spectrogram) giữa giọng đọc thực tế (Ground Truth) và giọng đọc do mô hình tổng hợp (Synthesized) sau 600 epoch.



Hình 13: So sánh phổ Mel trên mẫu câu ngắn: Giọng tổng hợp có xu hướng đọc chậm và rõ hơn.



Hình 14: So sánh phổ Mel trên mẫu câu dài: Cấu trúc hài âm và nhịp điệu được duy trì tốt.

Quan sát các Hình 13 và 14 cho thấy mô hình Matcha-TTS tích hợp PhoBERT đã đạt được độ trung thực cao về mặt cấu trúc phổ, đồng thời thể hiện những đặc trưng riêng biệt về nhịp điệu.

Thứ nhất, về cấu trúc phổ (Spectral Structure), mô hình khôi phục chính xác các đường vân hài âm (harmonics) và vùng cộng hưởng (formants). Nhờ cơ chế Flow Matching, các chi tiết ở dải tần số cao không bị mất đi hay làm mờ (oversmoothing), giúp âm thanh đầu ra có độ sắc nét và trong trẻo, loại bỏ được tạp âm nền (noise floor) xuất hiện trong bản thu gốc.

Thứ hai, về ngữ điệu (Prosody), sự hỗ trợ của PhoBERT thể hiện rõ qua sự biến thiên linh hoạt của các đường bao cao độ (pitch contours). Thay vì là những đường thẳng đơn điệu, phổ âm của giọng máy có độ uốn lượn tương đồng với giọng thật, chứng tỏ mô hình đã nắm bắt được ngữ cảnh để nhấn nhá phù hợp.

Thứ ba, về thời lượng và căn chỉnh (Duration & Alignment), có thể quan sát thấy tổng thời gian của giọng tổng hợp thường dài hơn so với giọng thật (ví dụ: tại Hình 13, giọng máy kéo dài đến 3.0s so với 2.4s của giọng gốc). Hiện tượng giãn nở thời gian này không phải là lỗi căn chỉnh sai (misalignment) mà phản ánh chiến lược tối ưu hóa của bộ dự báo thời lượng (Duration Predictor). Trong quá trình huấn luyện, mô hình có xu hướng học tốc độ đọc "trung bình" và ưu tiên độ rõ ràng (clarity/intelligibility). Do đó, mô hình thường tự động kéo dài nhẹ các nguyên âm và nối rộng các khoảng lặng giữa các cụm từ để đảm bảo người nghe nghe rõ từng tiếng. Mặc dù tốc độ đọc chậm hơn, nhưng tỷ lệ phân bố thời gian tương đối (relative timing) giữa các âm tiết vẫn được giữ cân đối, không xuất hiện hiện tượng nói lắp hay ngắt quãng bất thường.

4.5.3 Kết quả định lượng trên tập kiểm thử

Sau quá trình huấn luyện trên hệ thống 02 GPU Tesla T4 với tập dữ liệu khoảng 7 giờ, mô hình hoàn chỉnh (Proposed) được đánh giá trên tập kiểm thử (test set). Kết quả các chỉ số đo lường được tổng hợp trong Bảng 1.

Các chỉ số định lượng tại Bảng 1 phản ánh năng lực thực tế của mô hình trong việc tổng hợp tiếng nói tiếng Việt.

Về khả năng chuyển tải nội dung (Intelligibility), mức WER 26.74% và CER 16.96% cho thấy mô hình đã đạt được độ chính xác cơ bản trong việc phát âm, đảm bảo người nghe có thể

Bảng 1: Kết quả đánh giá định lượng mô hình Matcha-TTS (Phiên bản đề xuất).

Độ đo	Giá trị	Ý nghĩa đánh giá
WER (↓)	26.74 %	Tỷ lệ lỗi từ
CER (↓)	16.96 %	Tỷ lệ lỗi ký tự
F0 RMSE (↓)	62.49 Hz	Sai lệch cao độ trung bình
F0 Correlation (↑)	0.3606	Tương quan biến thiên cao độ
Predicted MOS (↑)	2.66 / 5.0	Điểm chất lượng (UTMOS)

hiều được phần lớn nội dung văn bản. Tỷ lệ lỗi hiện tại phản ánh những thách thức đặc thù của ngôn ngữ, đặc biệt là đối với các từ vay mượn, tên riêng hoặc các cấu trúc câu có sự biến đổi âm vị phức tạp tại biên giới các từ, nơi mô hình đôi khi vẫn gặp khó khăn trong việc dự đoán chính xác hoàn toàn.

Về khía cạnh ngữ điệu (Prosody), chỉ số F0 Correlation đạt mức 0.3606 là một tín hiệu tích cực đối với một hệ thống tổng hợp tiếng nói đơn lẻ. Giá trị dương này cho thấy đường bao cao độ (pitch contour) do mô hình sinh ra có xu hướng biến thiên đồng pha với giọng người thật, nghĩa là mô hình đã học được cách lên giọng, xuống giọng đúng ngữ cảnh thay vì phát ra các âm thanh phẳng (flat) hoặc ngẫu nhiên. Kết hợp với chỉ số F0 RMSE ở mức 62.49 Hz, có thể thấy mô hình đã kiểm soát được biên độ dao động của cao độ trong phạm vi chấp nhận được, hạn chế các lỗi chênh phô quá lớn.

Cuối cùng, chỉ số Predicted MOS đạt 2.66/5.0 theo đánh giá của hệ thống UTMOS. Trong thang đo chất lượng âm thanh tổng hợp, mức điểm này được xếp loại ở mức "Khá" (Fair), biểu thị rằng giọng đọc có độ rõ ràng tốt, ít nhiễu nền và nghe tự nhiên ở mức độ hội thoại thông thường. Tuy nhiên, do đây là điểm số được dự đoán bởi thuật toán máy học (thường được huấn luyện trên tập dữ liệu đa ngôn ngữ), kết quả này có thể mang tính khắt khe hơn và chưa phản ánh trọn vẹn các sắc thái biểu cảm tinh tế đặc trưng của tiếng Việt mà tai người có thể cảm nhận được.

4.5.4 Đánh giá hiệu quả cải tiến và vai trò của tích hợp mô hình ngữ điệu

Để kiểm chứng hiệu quả thực tế của các cải tiến, nghiên cứu thiết lập so sánh đối chứng giữa hai phiên bản: Baseline (sử dụng kiến trúc Matcha-TTS tiêu chuẩn) và Proposed (sử dụng kiến trúc cải tiến tích hợp Prosody Aligner với PhoBERT). Kết quả định lượng được tổng hợp chi tiết tại Bảng 2.

Bảng 2: So sánh hiệu năng giữa Baseline và Proposed (tích hợp PhoBERT).

Tiêu chí	Baseline	Proposed (w/ PhoBERT)	Mức độ thay đổi
WER (↓)	29.07%	26.74%	Cải thiện 2.33 %
CER (↓)	15.04%	16.96%	Dao động 1.92 %
F0 RMSE (↓)	72.28 Hz	2.49 Hz	Giảm sai số 9.79 Hz
F0 Corr (↑)	0.1700	0.3606	Tăng gấp 2.1 lần
MOS (↑)	2.52	2.66	Tăng 0.14 điểm

Phân tích số liệu thực nghiệm cho thấy sự chuyển biến tích cực trong hiệu năng mô hình là kết quả tổng hợp của việc nâng cao chất lượng dữ liệu và thay đổi kiến trúc mạng với cơ chế phân tích ngữ điệu (Prosody Analysis).

Về khả năng tái tạo nội dung (Intelligibility), kết quả ghi nhận một sự đánh đổi thú vị về mặt kỹ thuật: trong khi tỷ lệ lỗi từ (WER) cải thiện từ 29.07% xuống 26.74%, thì tỷ lệ lỗi ký tự (CER) lại có sự gia tăng nhẹ. Điều này được lý giải bởi sự thay đổi trong cơ chế học của mô hình. Phiên bản Baseline có xu hướng tập trung tối ưu hóa cục bộ từng âm vị (phoneme-level), dẫn đến CER thấp nhưng thiếu tính liên kết ngữ nghĩa. Ngược lại, phiên bản Proposed, nhờ sự

hỗ trợ của PhoBERT, đã chuyển trọng tâm sang việc nắm bắt ngữ cảnh toàn cục (sentence-level context). Điều này giúp mô hình dự đoán từ vựng chính xác hơn (giảm WER) và duy trì sự trôi chảy của câu nói, chấp nhận một sai số nhỏ ở cấp độ ký tự để đổi lấy sự tự nhiên trong dòng chảy âm thanh.

Bước tiến đột phá nhất của nghiên cứu nằm ở các chỉ số ngữ điệu (Prosody), với F0 Correlation tăng gấp 2.1 lần (từ 0.17 lên 0.3606) và F0 RMSE giảm gần 10 Hz. Sự khác biệt vượt trội này minh chứng cho vai trò tiên quyết của việc tích hợp mô hình ngôn ngữ tiền huấn luyện. Trong khi kiến trúc Baseline chỉ dựa vào chuỗi ký tự đầu vào để "phỏng đoán" cao độ một cách máy móc, dẫn đến giọng đọc đều đều (monotone), thì phiên bản Proposed tận dụng khả năng hiểu ngôn ngữ của PhoBERT để trích xuất các vector đặc trưng ngữ điệu (prosody embeddings) giàu thông tin. Nhờ đó, bộ giải mã Flow Matching có cơ sở dữ liệu ngữ nghĩa để sinh ra các đường bao cao độ (pitch contours) biến thiên linh hoạt, mô phỏng chính xác các điểm nhấn giọng, ngắt nghỉ cảm xúc tương tự như người thật.

Tổng hợp lại, sự kết hợp giữa quy trình tiền xử lý dữ liệu chặt chẽ và kiến trúc nhận thức ngữ cảnh (context-aware architecture) đã giúp mô hình không chỉ đọc đúng văn bản mà còn thể hiện được sắc thái biểu cảm, nâng điểm đánh giá chất lượng tổng thể (MOS) lên 2.66. Kết quả này khẳng định hướng tiếp cận sử dụng các mô hình ngôn ngữ lớn (PLMs) làm nền tảng cho Prosody Aligner là giải pháp tối ưu cho bài toán tổng hợp tiếng nói tiếng Việt.

5 Kết luận và hướng phát triển

5.1 Kết luận

Bài báo đã trình bày một khung tiếp cận tích hợp giữa mô hình ngôn ngữ lớn (LLM) và hệ thống tổng hợp tiếng nói (TTS) nhằm cải thiện ngữ điệu trong bài toán đọc văn bản tự động tiếng Việt. Trên nền tảng Matcha-TTS với Optimal-Transport Conditional Flow Matching (OT-CFM), nghiên cứu tập trung vào hai đóng góp chính: (i) xây dựng pipeline xử lý dữ liệu *in-the-wild* gồm 5 giai đoạn (Silero-VAD, Demucs, Whisper, PhoGPT kết hợp luật chuẩn hóa) để tạo các cặp (audio, text) sạch và nhất quán; và (ii) thiết lập hướng điều kiện hóa ngữ điệu bằng tín hiệu prosody có cấu trúc do LLM suy diễn, tạo tiền đề cho cơ chế điều khiển biểu cảm trong quá trình tổng hợp. Kết quả thực nghiệm cho thấy pipeline đề xuất giúp cải thiện chất lượng dữ liệu huấn luyện, giảm nhiễu nền, ổn định căn chỉnh và nâng cao chất lượng phổ mel tái tạo; đồng thời mô hình Matcha-TTS thể hiện xu hướng hội tụ ổn định qua các thành phần hàm mất mát và tạo đầu ra có nhịp điệu ngắt nghỉ hợp lý. Các chỉ số định lượng (WER/CER, F0 RMSE/F0 correlation, MOS dự đoán) cho thấy hệ thống đạt hiệu năng phù hợp với bối cảnh tài nguyên hạn chế và có tiềm năng triển khai gần thời gian thực. Tổng hợp lại, nghiên cứu khẳng định tính khả thi của hướng LLM-TTS trong việc tăng cường prosody cho tiếng Việt, đồng thời nhấn mạnh vai trò quyết định của chất lượng dữ liệu và cơ chế điều kiện hóa ngữ điệu trong việc nâng cao tính tự nhiên và biểu cảm của giọng đọc.

5.2 Hướng phát triển

Trong tương lai, nghiên cứu có thể mở rộng theo bốn hướng chính. Thứ nhất, về dữ liệu, cần tăng độ đa dạng theo vùng miền, tốc độ nói và mức độ biểu cảm, đồng thời bổ sung chiến lược lọc chất lượng tự động (quality filtering) và kiểm soát sai lệch miền dữ liệu nhằm giảm tác động của nhiễu và lỗi phiên âm trong môi trường *in-the-wild*. Thứ hai, về mô hình, có thể nghiên cứu tối ưu hóa suy luận OT-CFM/ODE (ví dụ lựa chọn solver hiệu quả hơn hoặc distillation theo số bước) để giảm độ trễ, đồng thời tăng khả năng tổng quát hóa với văn bản dài và cấu trúc phức tạp. Thứ ba, về điều khiển ngữ điệu, cần thiết kế biểu diễn prosody có cấu trúc hơn (prosody tokens, SSML mở rộng, hoặc latent prosody embedding đa thang) và cơ chế *prosody fusion* chặt chẽ giữa tín hiệu từ LLM và điều kiện âm học, hướng tới điều khiển tường minh các thuộc tính như nhấn trọng tâm, khoảng dừng, tốc độ đọc và sắc thái cảm xúc. Thứ tư, về đánh giá, cần triển khai đánh giá MOS với người nghe bản ngữ theo giao thức chuẩn hội nghị và bổ sung các thước đo khách quan chuyên biệt cho tiếng Việt (so khớp F0/energy/duration

theo đơn vị âm tiết, đo độ tự nhiên ngắt nghỉ, và phân tích lỗi theo loại từ/đơn vị thanh điệu). Các hướng phát triển này kỳ vọng sẽ nâng chất lượng giọng đọc lên mức tiệm cận giọng người, đồng thời tăng khả năng kiểm soát và tính ứng dụng của hệ thống trong các bài toán thực tế như audiobook, trợ lý ảo, giáo dục và hỗ trợ tiếp cận thông tin.

Tài liệu tham khảo

- [1] A. van den Oord, S. Dieleman, H. Zen, K. Simonyan, O. Vinyals, A. Graves, N. Kalchbrenner, A. Senior, and K. Kavukcuoglu, *WaveNet: A Generative Model for Raw Audio*, 2016.
- [2] J. Shen, R. Pang, R. J. Weiss, E. Battenberg, Y. Chen, G. Novik, S. Sercu, and A. Coates, *Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions (Tacotron 2)*, 2017/2018.
- [3] R. Prenger, R. Valle, and B. Catanzaro, *WaveGlow: A Flow-based Generative Network for Speech Synthesis*, 2018.
- [4] R. Yamamoto, E. Song, and J.-M. Kim, *Parallel WaveGAN: A Fast, High-Fidelity Neural Vocoder*, 2019/2020.
- [5] Y. Ren, Y. Ruan, X. Tan, S. Qin, Z. Zhao, and T.-Y. Liu, *FastSpeech: Fast, Robust and Controllable Text to Speech*, 2019.
- [6] Y. Ren, Y. Ruan, X. Tan, S. Qin, Z. Zhao, and T.-Y. Liu, *FastSpeech 2: Fast and High-Quality Speech Synthesis via Non-Autoregressive Models*, 2020.
- [7] J. Kong, J. Kim, and J. Bae, *HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis*, 2020.
- [8] J. Kong, J. Kim, J. Bae, and J. Seo, *DiffWave: A Versatile Diffusion Model for Audio Synthesis*, 2020.
- [9] N. Chen, Y. Zhang, H. Zen, C. Weng, Z. Yu, and C. Wang, *WaveGrad: Estimating Gradients for Waveform Generation*, 2020/2021.
- [10] J. Kim, S. Kim, J. Kong, and S. Yoon, *Glow-TTS: A Generative Flow for Text-to-Speech via Monotonic Alignment Search*, 2020.
- [11] J. Kim, J. Kim, J. Kong, and S. Yoon, *VITS: Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech*, 2021.
- [12] V. Popov, I. Vovk, V. Gogoryan, et al., *Grad-TTS: A Diffusion Probabilistic Model for Text-to-Speech*, 2021.
- [13] E. Casanova, J. Weber, C. D. Shulby, et al., *YourTTS: Zero-Shot Multi-Speaker Text-to-Speech with Quality and Control*, 2022.
- [14] S.-g. Lee, W. Ping, B. Ginsburg, et al., *BigVGAN: A Universal Neural Vocoder with Large-Scale Training*, 2022.
- [15] K. Shen, Z. Ju, X. Tan, et al., *NaturalSpeech 2: Latent Diffusion Models are Effective for Zero-Shot Text-to-Speech*, 2023.
- [16] H. B. Le, et al., *Voicebox: Text-Guided Speech Infilling and Editing*, 2023.
- [17] Y. A. Li, C. Han, V. S. Raghavan, et al., *StyleTTS 2: Towards Human-Level Expressive Text-to-Speech with Style Diffusion and Adversarial Training*, 2023.

- [18] X. Zhang, D. Zhang, S. Li, et al., *SpeechTokenizer: Unified Speech Tokenizer for Speech Large Language Models*, 2023.
- [19] Z. Ju, et al., *NaturalSpeech 3: Zero-Shot TTS with Factorized Codec and Diffusion Models*, 2024.
- [20] C. Wang, et al., *VALL-E: Neural Codec Language Models are Zero-Shot Speech Synthesizers*, 2023.
- [21] S. Mehta, R. Tu, J. Beskow, É. Székely, and G. E. Henter, *Matcha-TTS: A fast TTS architecture with conditional flow matching*, arXiv:2309.03199, accepted to IEEE ICASSP 2024. <https://arxiv.org/abs/2309.03199>
- [22] OpenAI, *Whisper: Robust Speech Recognition via Large-Scale Weak Supervision*, 2022.
- [23] A. Défossez, et al., *Demucs (Music Source Separation)*, repository/documentation. <https://github.com/facebookresearch/demucs>
- [24] Silero Team, *Silero-VAD (Voice Activity Detection)*, repository/documentation. <https://github.com/snakers4/silero-vad>
- [25] UTMOS authors, *UTMOS: automatic MOS prediction for speech*, model/resource documentation.
- [26] PhoGPT authors/community, *PhoGPT (Vietnamese LLM) model/resource documentation*, Hugging Face model card. <https://huggingface.co>